Neural Networks and Deep Learning

Summer School Kunag yaming Honors School 吴胜俊教授

Textbook: Michael A. Nielsen "Neural NEtworks and Deep Learning

• Online version: 链接

Contents:

- Introduction
- · Neural networks and learning
- · Backpropagation algorithm
- Neural nets to compute any function
- · Improving the way neural nets learn
- · Deep neural nets
- · Deep learning with ALphaGo
- · Quantum neural network and learning

Introduction

- 解决的问题:
 - 。 图像识别
 - 。声音识别
 - 。自然语言处理
 - o etc
- 课程例子:
 - 。 手写数字的识别:
 - 对于人类easy
 - 对于rule-based 算法: hard;
 - 。 解决的方法:
 - Segmentation: 分段,切片;
 - 分类;
 - Classifying individual digit:
 - 输入数据集:[0.0,1.0]^{28×28}

- 函数f(进行分类);
- 输出数据集: {0,1....,9} (Class labels)
- 。 Segmentation 问题可能的方法;
 - 试图分类
 - 用一个individual digit classfier 对上面的分类进行打分
 - 高分,低分反馈,然后继续分类;
 - 得到最高分的分类

神经网络

- 定义: 神经网络是一个神经元的网络。主要有: 输入层,隐藏层(可以有很多很多层),输出层;
- 学习目标:
 - 。神经元的强度
 - 。 通过输入数据神经网络来调整神经元的强度,这就是学习/训练的过程
- Perceptrons(感知机)
 - 。 **感知机**是一种抽象化(人造)的神经元;
 - 。 根据输入的X得到二进制的输出:

$$f(x) = egin{cases} 0 & if \sum_j w_j x_j \leq$$
 阈值 $1 & if \sum_j w_j x_j >$ 阈值

- 。 符号规约:
 - $\sum_j w_j x_j$ 写成 $w \cdot x$
 - 取b=-threshold

$$f(x) = egin{cases} 0 & if \sum_j w \cdot x + b \leq 0 \ 1 & if \sum_j w \cdot x + b > 0 \end{cases}$$


- 。 实现NAND(↑)gate (非或)
 - e.g, $w = (-2, -2)^T$
 - Bias: b=3

Α	В	A NAND B
0	0	1

A	В	A NAND B
0	1	1
1	0	1
1	1	0

• Sigmoid 神经元;

- $\circ w + \Delta w$
- 。 之前的感知器不连续,会变化过于剧烈
- \circ Sigmoid neuron: $\text{output=} \sigma(w\cdot x + b)$ sigmoid function: $\sigma(z) = \tfrac{1}{1+e^{-z}}$
- 。 sigmoid 是0-1的一个连续函数;



。 反向传播的时候很香,求导简单;

$$\circ \hspace{1cm} \Delta output pprox \sum rac{\partial \ output}{\partial w_{j}} \Delta w_{j} + rac{\partial \ output}{\partial b} \Delta b_{j}$$

$$\circ \ \sigma(z)' = rac{e^{-z}}{(1+e^{-z})^2}$$

 Feedforward neural networks No loops;

- Why 10 ouotput nuerons are needed?
 用十个比较离散的输出有利于:1. 比较 2.结果理解性比较强;
- 梯度下降法学习:
 - 。 Cost function: 当前的神经网络输出的结果有多好;

$$C(w,b)=rac{1}{2n}\sum_n||y(x)-a||^2$$

- w:network中的权重集合
- b:所有的bias集合;
- n:训练集的个数;
- x: 输入的vector;
- y=y(x): 输出的向量;
- a=a(w,b,x):network这一轮训练的结果;
- 。 C(w,b)是一个非负的二次函数'
- 。 梯度下降:
 - Minimize C(v):

$$\Delta C \approx \nabla C \cdot \Delta v$$

- $\nabla C[\frac{\partial C}{\partial v_1}...\frac{\partial C}{\partial v_m}]$ (梯度的方向)
- $lacksquare \Delta = -\eta igtriangledown C$
- *η*是学习率;
- 。 因此更新规则:
 - $\mathsf{w} \leftarrow \mathsf{w} \text{-} \eta \bigtriangledown_w C$
 - b \leftarrow w- $\eta \bigtriangledown_b C$
- 。 SGD:随机梯度下降;
- 。 怎么算 $∇_w$:反向传播算法(BP)
- SGD:
 - 。 随机从训练集里面选择一部分数据进行▽C的训练;
 - 。 Mini-batch: 就是用m个随机出来的数据训练;
 - 。 Epoch(训练轮次)
- 反向传播算法:
 - 。 定义:
 - w^l_{jk} : the weight for the connection from the k-th neuron in the l-1 th layer to the j-th nueron in th lth layer
 - b_i^l : the bias of the j-th neuron in the l-th layer
 - a_j^l : the activation of the j-th neuron in the l-th layer

$$oldsymbol{a} a_j^l = \sigma(\sum_k w_{jk}^l a_k^{l-1} + b_j^l); \sigma: sigmoid\ function$$

$$\bullet \ \ \mathrm{i} \exists z^l = w^l a^{l-1} + b^l$$

$$lacksquare a^l = \sigma(z^l)$$

$$C = \frac{1}{n} \sum_{x} C_x$$

- \circ Derive $\bigtriangledown_w C_x$ and $\bigtriangledown_b C_x$
 - all subscripts x of C_x are omitted;
 - error:第I层神经元的错误:

$$\delta_k^l = rac{\partial C}{\partial z^l}$$

■ 某种神奇的乘法符号;

$$(s\odot t)_j=s_jt_j$$

o BP:

0

1. the error in the output layer σ^L :

$$\delta_j^l = rac{\partial C}{\partial a_j^L} \sigma^l(z_j^L)$$

$$\delta^L = \nabla_a C \odot \sigma'(z^L)$$

$$\delta^L = (a^L - y) \odot \sigma'(Z^L)$$

2. the error σ^L in terms of the error in the next layer σ^{l+1} :

$$\sigma^l = ((w^{l+1})^T \sigma^{l+1}) \odot \sigma'(z^l)$$

(用来递归求解);

3. the rate of change of the cost with respect to any bias:

$$rac{\partial C}{\partial b_j^l} = \delta_j^l$$

$$\frac{\partial C^j}{\partial b} = \sigma$$

4. the rate of change of the cost with respect to ant weight:

$$\frac{\partial C}{\partial w_{jk}^\top} = a_k^{l-1} \sigma_j^l$$

$$\frac{\partial C}{\partial w} = a_{in}\sigma_{out}$$

- 。 BP实际操作;
 - 1. Input x;

对每一个input layer 设置corresponding activation a^l ;

2. Feedforward:

For each I=3,...,L compute $z^l=w^la^{l-1}+b^l$ and $a^l=\sigma(z^l)$

3. Ouyput error σ^L 计算vector $\sigma^L \bigtriangledown_a C \odot \sigma'(z^l)$

4. Backpropagate the error;

For each I=L-1,...,2 compute $\sigma^l = ((w^{l+1})^T \sigma^{l+1}) \odot \sigma'(z^l)$

5. Output:

THe gradient of the cost function is given by $rac{\partial C}{\partial w_{jk}^l}=a_k^{l-1}\delta_j^l$ and $rac{\partial C}{\partial b_j^l}=\sigma_j^l$

- 一种实现的方法:
- MINST

-traning data:50,000 images

o test set: 10,000 images

- · Size of the network:
 - 784,30,10
- Hyper-parameters
 - o 30 epochs

o mini-atch size: 10

 \circ learning rate: $\eta=3.0$

Neural nets to compute any function

- the universality theorem
- 感知机的调戏方式:
 - 1. c 越大越接近阶跃
 - 2. -sc来调整位置
 - 3. 可以用两个神经元实现一个bump函数; (s_1, s_2) 之间取1,其余为0);

- 4. 一般的函数,有多少的分段就加多少的神经元
 - 可以康康这个网站

Improving the way neural nets learn

The cross-entyopy cost function

- Reason:
 - 。 sigmoid神经元会梯度消失;
- 解决方式:
 - 1. 改善cost-function:

$$C=-rac{1}{n}\sum_{x}[ylna+(1-y)ln(1-a)]$$

- 2. 推导:
- 。(看不懂)